Защищено:		Демонстрация: Гапанюк Ю.Е.		
Sащищено. Гапанюк Ю.Е.		"	2022 г.	
""	2022 г.			
Отч	ет по лабораторной раб Технологии машинно ГУИМЦ		pcy	
Тема рабо	гы: '' Линейные модели	ı, SVM и дереі	вья решений. ''	
	11 (количество листо <u>Вариант № <b>4</b></u>	ов)		
	ИСПОЛНИТЕЛЬ:			
	студент группы ИУ5Ц-84Б	(подпись	)	
	Шанаурина Е. Г.	""	2022 г.	
	Москва, МГТУ	- 2022		

## Цель лабораторной работы:

изучение линейных моделей, SVM и деревьев решений.

### Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train\_test\_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие модели:
  - одну из линейных моделей (линейную или полиномиальную регрессию при решении задачи регрессии, логистическую регрессию при решении задачи классификации);
  - o SVM;
  - о дерево решений.
- 5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.
- 6. Постройте график, показывающий важность признаков в дереве решений.
- 7. Визуализируйте дерево решений или выведите правила дерева решений в текстовом виде.

## Ход выполнения работы

В качестве набора данных используется dataset - Результаты студентов на экзаменах (Оценки, полученные учащимися по различным предметам).

Датасет доступен по адресу:

https://www.kaggle.com/datasets/spscientist/students-performance-in-exams

Из набора данных будет рассматриваться только файл « StudentsPerformance.csv»

## Лабораторная работа №4

Out[5]: <AxesSubplot:>

```
import numpy as np
In [1]:
          import pandas as pd
          from typing import Dict, Tuple
          import seaborn as sns
          import matplotlib.pyplot as plt
          %matplotlib inline
          from sklearn.impute import SimpleImputer
          import warnings
          from sklearn.pipeline import Pipeline
          from sklearn.preprocessing import PolynomialFeatures
          from sklearn.metrics import confusion_matrix, precision_score, recall_score, f1_scor
          from sklearn.linear_model import LinearRegression
          warnings.simplefilter("ignore")
In [2]:
          # чтение обучающей выборки
          data = pd.read_csv('StudentsPerformance.csv')
          data.head()
Out[2]:
                                                                      test
                                  parental level of
                                                                            math
                                                                                  reading writing
            gender race/ethnicity
                                                       lunch
                                                               preparation
                                       education
                                                                            score
                                                                                    score
                                                                                            score
                                                                    course
         0
             female
                         group B
                                  bachelor's degree
                                                     standard
                                                                      none
                                                                              72
                                                                                       72
                                                                                               74
             female
                                                                              69
                                                                                       90
         1
                         group C
                                      some college
                                                     standard
                                                                 completed
                                                                                               88
         2
             female
                         group B
                                   master's degree
                                                     standard
                                                                      none
                                                                              90
                                                                                       95
                                                                                               93
                                        associate's
         3
                                                  free/reduced
                                                                              47
                                                                                       57
                                                                                               44
              male
                         group A
                                                                     none
                                           degree
         4
                                     some college
                                                     standard
                                                                              76
                                                                                       78
                                                                                               75
              male
                         group C
                                                                      none
          from sklearn.model_selection import train_test_split
In [3]:
          from sklearn.preprocessing import LabelEncoder
In [4]:
          le = LabelEncoder()
              # "gender" - пол
          le.fit(data.gender.drop_duplicates())
          data.gender = le.transform(data.gender)
              # "race/ethnicity" - paca
          le.fit(data["race/ethnicity"].drop_duplicates())
          data["race/ethnicity"] = le.transform(data["race/ethnicity"])
              # "Lunch" - обед
          le.fit(data.lunch.drop_duplicates())
          data.lunch = le.transform(data.lunch)
              # "parental level of education" - образование родителей
          le.fit(data["parental level of education"].drop duplicates())
          data["parental level of education"] = le.transform(data["parental level of education
              # "test preparation course" - подготовительный курс
          le.fit(data["test preparation course"].drop_duplicates())
          data["test preparation course"] = le.transform(data["test preparation course"])
          #Построим корреляционную матрицу
In [5]:
          fig, ax = plt.subplots(figsize=(15,7))
          sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```



# Предскажем значения поля Writing score по Math score и Reading score, так как значение корреляции ближе всего к 1.

```
In [6]: X = data[["math score", "reading score"]]
Y = data["writing score"]
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head())
```

#### Входные данные:

	math	score	reading	score
0		72		72
1		69		90
2		90		95
3		47		57
4		76		78

#### Выходные данные:

```
0 74
1 88
2 93
3 44
4 75
```

Name: writing score, dtype: int64

Входные параметры обучающей выборки:

	math	score	reading	score
785		32		51
873		90		90
65		67		64
902		34		48
317		83		72

Входные параметры тестовой выборки:

math score reading score

```
    993
    62
    72

    859
    87
    73

    298
    40
    46

    553
    77
    62

    672
    69
    78
```

Выходные параметры обучающей выборки:

```
785 44
873 82
65 61
902 41
317 78
Name: writing score, dtype: int64
```

name: writing score; acype: inco-


Выходные параметры тестовой выборки:

```
993 74
859 72
298 50
553 64
672 76
Name: writing score, dtype: int64
```

## Построение линейной регрессии

# Возьмем тот параметр, чья корреляция ближе всего к единице, т.е. Reading score

```
In [10]: plt.scatter(X_test["reading score"], Y_test, marker = 's', label = 'Тестовая выбо
plt.scatter(X_test["reading score"], lr_y_pred, marker = 'o', label = 'Предсказанные
plt.legend (loc = 'lower right')
plt.xlabel ('Баллы по чтению')
plt.ylabel ('Целевой признак')
plt.show()
```



### **SVM**

In [11]: from sklearn.svm import SVC , LinearSVC

```
from sklearn.datasets.samples_generator import make_blobs
           from matplotlib import pyplot as plt
In [12]:
          svc = SVC(kernel='linear')
          svc.fit(X_train,Y_train)
         SVC(kernel='linear')
Out[12]:
          pred_y = svc.predict(X_test)
In [13]:
In [14]:
          plt.scatter(X test["reading score"], Y test,
                                                            marker = 's', label = 'Тестовая выбо
          plt.scatter(X_test["reading score"], pred_y, marker = 'o', label = 'Предсказанные да
          plt.legend (loc = 'lower right')
          plt.xlabel ('Баллы по чтению')
          plt.ylabel ('Целевой признак')
          plt.show()
            100
             90
             80
          Целевой признак
             70
             60
             50
             40
             30
                                             Тестовая выборка
                                             Предсказанные данные
             20
                  30
                        40
                              50
                                     60
                                           70
                                                             100
                                  Баллы по чтению
         Tree
          from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export_graph
In [15]:
          from sklearn.tree import export_graphviz
          from sklearn import tree
          import re
In [16]:
          # Обучим дерево на всех признаках iris
          clf = tree.DecisionTreeClassifier()
          clf = clf.fit(X_test, Y_test)
In [17]:
          from IPython.core.display import HTML
          from sklearn.tree.export import export_text
          tree_rules = export_text(clf, feature_names=list(X.columns))
          HTML('' + tree_rules + '')
          --- reading score <= 61.00
Out[17]:
               --- math score <= 64.50
                    -- math score <= 53.00
                       --- reading score <= 56.50
                           |--- math score <= 46.50
                                |--- reading score <= 31.50
                                    |--- class: 30
                                 --- reading score > 31.50
                                    |--- math score <= 36.00
                                         |--- class: 43
                                    |--- math score > 36.00
```

```
|--- reading score <= 38.00
                                |--- class: 36
                             --- reading score > 38.00
                                |--- reading score <= 42.50
                                   |--- class: 38
                                --- reading score > 42.50
                                   |--- math score <= 41.00
                                        |--- class: 50
                                   |--- math score > 41.00
                                       |--- math score <= 43.00
                                           |--- class: 54
                                        |--- math score > 43.00
                                        | |--- truncated branch of depth 2
                    math score >
                                  46.50
                    |--- reading score <= 45.00
                       |--- class: 35
                    --- reading score > 45.00
                        --- reading score <= 53.50
                           |--- class: 58
                       |--- reading score > 53.50
                           |--- math score <= 47.50
                              |--- class: 53
                            |--- math score > 47.50
                           1
                               |--- class: 58
              -- reading score > 56.50
               |--- reading score <= 58.00
                   |--- class: 56
                |--- reading score > 58.00
                   |--- class: 56
         -- math score > 53.00
            |--- reading score <= 49.50
               |--- math score <= 58.50
                    |--- math score <= 54.50
                      |--- class: 52
                   |--- math score > 54.50
                       |--- reading score <= 47.00
                          |--- class: 44
                        |--- reading score > 47.00
                       | |--- class: 51
                |--- math score > 58.50
                  |--- class: 47
           |--- reading score > 49.50
               |--- math score <= 63.00
                   |--- reading score <= 53.00
                      |--- class: 52
                   |--- reading score > 53.00
                      |--- class: 55
                |--- math score > 63.00
                   |--- class: 52
    --- math score > 64.50
       |--- reading score <= 57.00
           |--- class: 57
       |--- reading score > 57.00
           |--- reading score <= 59.00
              |--- class: 53
           |--- reading score > 59.00
              |--- class: 57
|--- reading score > 61.00
```

```
--- reading score <= 68.50
    |--- reading score <= 66.50
        |--- math score <= 69.50
            |--- math score <= 60.00
               |--- reading score <= 62.50
                    |--- math score <= 45.50
                       |--- class: 61
                    --- math score > 45.50
                       |--- math score <= 53.50
                          |--- class: 60
                        |--- math score > 53.50
                         |--- class: 64
                --- reading score > 62.50
                   |--- reading score <= 63.50
                       |--- class: 62
                    |--- reading score > 63.50
                       |--- math score <= 55.00
                           |--- reading score <= 64.50
                              |--- class: 68
                           |--- reading score > 64.50
                            | |--- class: 65
                        --- math score > 55.00
                            |--- class: 63
               math score > 60.00
                |--- reading score <= 62.50
                   |--- class: 60
                --- reading score > 62.50
                    |--- reading score <= 65.50
                       |--- class: 61
                   |--- reading score > 65.50
                        |--- math score <= 62.00
                           |--- class: 61
                        |--- math score > 62.00
                         |--- class: 67
          - math score > 69.50
            |--- reading score <= 64.50
                |--- reading score <= 63.00
                   |--- class: 64
               --- reading score > 63.00
                   |--- math score <= 73.00
                   | |--- class: 70
                   |--- math score > 73.00
                   | |--- class: 66
            --- reading score > 64.50
               |--- class: 60
    --- reading score > 66.50
       |--- class: 67
    reading score > 68.50
    --- reading score <= 70.50
        --- reading score <= 69.50
           |--- math score <= 63.00
           | |--- class: 65
            |--- math score > 63.00
              |--- class: 75
       |--- reading score > 69.50
           |--- math score <= 71.50
               |--- math score <= 59.00
                   |--- math score <= 55.50
```

```
|--- class: 70
              |--- math score > 55.50
                 |--- class: 68
          |--- math score > 59.00
              |--- class: 70
       --- math score > 71.50
         |--- class: 75
-- reading score > 70.50
 |--- reading score <= 81.50
      |--- reading score <= 77.50
          |--- math score <= 76.50
              |--- math score <= 74.50
                  |--- reading score <= 75.00
                      |--- math score <= 57.50
                          |--- class: 64
                      |--- math score > 57.50
                          |--- math score <= 62.50
                              |--- class: 74
                          |--- math score > 62.50
                             |--- reading score <= 72.50
                                 |--- class: 77
                              |--- reading score > 72.50
                                  |--- truncated branch of depth 3
                              |--- reading score > 75.00
                      |--- math score <= 54.50
                         |--- class: 70
                      |--- math score > 54.50
                          |--- reading score <= 76.50
                             |--- class: 80
                          |--- reading score > 76.50
                              |--- math score <= 61.00
                                 |--- class: 80
                              |--- math score > 61.00
                              | --- truncated branch of depth 2
               --- math score >
                                74.50
                  |--- class: 68
          |--- math score > 76.50
              |--- reading score <= 74.00
                  |--- reading score <= 72.50
                      |--- math score <= 79.50
                        |--- class: 69
                      |--- math score > 79.50
                      | |--- class: 73
                  |--- reading score > 72.50
                     |--- class: 72
              |--- reading score > 74.00
                  |--- reading score <= 75.50
                     |--- class: 76
                  |--- reading score > 75.50
                     |--- reading score <= 76.50
                        |--- class: 74
                      |--- reading score > 76.50
                      1
                         |--- class: 73
        -- reading score > 77.50
          |--- math score <= 73.50
              |--- math score <= 58.00
                 |--- class: 79
              |--- math score > 58.00
```

```
|--- reading score <= 78.50
                   |--- class: 76
                --- reading score > 78.50
                   |--- class: 79
          -- math score > 73.50
            |--- math score <= 87.50
                |--- reading score <= 78.50
                   |--- class: 81
               |--- reading score > 78.50
                   |--- reading score <= 79.50
                      |--- math score <= 76.50
                       | |--- class: 80
                       |--- math score > 76.50
                       | |--- class: 78
                   |--- reading score > 79.50
                   | |--- class: 80
            |--- math score > 87.50
                |--- math score <= 91.50
                  |--- class: 79
                |--- math score > 91.50
                   |--- class: 84
|--- reading score > 81.50
    |--- reading score <= 89.50
        |--- math score <= 74.00
           |--- reading score <= 85.00
              |--- class: 83
           |--- reading score > 85.00
               |--- class: 82
       |--- math score > 74.00
            |--- math score <= 78.00
               |--- class: 91
            |--- math score > 78.00
                |--- math score <= 84.50
                   |--- reading score <= 87.00
                   | |--- class: 86
                   |--- reading score > 87.00
                   | |--- class: 89
                |--- math score > 84.50
                   |--- math score <= 91.50
                      |--- class: 75
                    |--- math score > 91.50
                       |--- reading score <= 85.50
                       | |--- class: 90
                       --- reading score > 85.50
                       | |--- math score <= 96.50
                           | |--- class: 92
                           |--- math score > 96.50
                              |--- class: 81
     -- reading score > 89.50
        |--- math score <= 79.00
           |--- class: 88
        |--- math score > 79.00
            |--- math score <= 81.50
               |--- class: 87
            --- math score > 81.50
                |--- math score <= 87.00
                 |--- class: 93
```

```
In [18]: pred_y = clf.predict(X_test)
    plt.scatter(X_test["reading score"], Y_test, marker = 's', label = 'Тестовая выбо
    plt.scatter(X_test["reading score"], pred_y, marker = 'o', label = 'Предсказанные да
    plt.legend (loc = 'lower right')
    plt.xlabel ('Баллы по чтению')
    plt.ylabel ('Целевой признак')
    plt.show()
```

